

Analisi del dataset Boston sulla variabilità del prezzo mediano

Jacopo Timo

2025-06-06

Il dataset “Boston” raccoglie al suo interno diversi dati, ordinati tramite 14 variabili e 506 osservazioni inerenti alle zone residenziali dell’omonima città del Massachusetts. L’obiettivo di questa ricerca è quello di spiegare come il prezzo mediano (medv) di un’abitazione bostoniana cambi in base all’influenza delle altre variabili presenti nel dataset. Più precisamente, prenderemo in considerazione la variabilità del prezzo mediano basandoci sul numero di stanze (rm) presenti nelle abitazioni e, per verificare se vi sia una relazione tra le due, ci aiuteremo attraverso la costruzione di un modello di regressione lineare semplice in cui:

Y = prezzo mediano per abitazione, sarà la nostra variabile risposta

X = numero di stanze presenti, sarà la nostra variabile esplicativa

In seguito, proveremo a potenziare il nostro modello affiancando alla variabile rm un’altra variabile esplicativa, quella di lstat, in riferimento alla percentuale di persone appartenenti a contesti socio-economici più svantaggiati.

Iniziamo caricando i pacchetti necessari per la nostra ricerca e calcolando le statistiche descrittive del nostro dataset:

```
library(MASS)
library(ISLR2)

##
## Attaching package: 'ISLR2'

## The following object is masked from 'package:MASS':
##
##      Boston

library(ggplot2)
library(reshape2)
library(corrplot)

## corrplot 0.95 loaded

boston <- read.csv("/Users/jacopo/Desktop/Modelli Statistici/Boston.csv")
head(boston)
```

```
##      X      crim zn indus chas      nox      rm      age      dis rad tax ptratio lstat medv
## 1 1 0.00632 18 2.31      0 0.538 6.575 65.2 4.0900      1 296      15.3 4.98 24.0
## 2 2 0.02731  0 7.07      0 0.469 6.421 78.9 4.9671      2 242      17.8 9.14 21.6
## 3 3 0.02729  0 7.07      0 0.469 7.185 61.1 4.9671      2 242      17.8 4.03 34.7
## 4 4 0.03237  0 2.18      0 0.458 6.998 45.8 6.0622      3 222      18.7 2.94 33.4
## 5 5 0.06905  0 2.18      0 0.458 7.147 54.2 6.0622      3 222      18.7 5.33 36.2
## 6 6 0.02985  0 2.18      0 0.458 6.430 58.7 6.0622      3 222      18.7 5.21 28.7
```

`summary(boston)`

```
##           X           crim           zn           indus
##  Min.   : 1.0      Min.   : 0.00632      Min.   : 0.00      Min.   : 0.46
## 1st Qu.:127.2      1st Qu.: 0.08205      1st Qu.: 0.00      1st Qu.: 5.19
## Median :253.5      Median : 0.25651      Median : 0.00      Median : 9.69
## Mean   :253.5      Mean   : 3.61352      Mean   : 11.36      Mean   :11.14
## 3rd Qu.:379.8      3rd Qu.: 3.67708      3rd Qu.: 12.50      3rd Qu.:18.10
## Max.   :506.0      Max.   :88.97620      Max.   :100.00      Max.   :27.74
##           chas           nox           rm           age
##  Min.   :0.00000      Min.   :0.3850      Min.   :3.561      Min.   : 2.90
## 1st Qu.:0.00000      1st Qu.:0.4490      1st Qu.:5.886      1st Qu.: 45.02
## Median :0.00000      Median :0.5380      Median :6.208      Median : 77.50
## Mean   :0.06917      Mean   :0.5547      Mean   :6.285      Mean   : 68.57
## 3rd Qu.:0.00000      3rd Qu.:0.6240      3rd Qu.:6.623      3rd Qu.: 94.08
## Max.   :1.00000      Max.   :0.8710      Max.   :8.780      Max.   :100.00
##           dis           rad           tax           ptratio
##  Min.   : 1.130      Min.   : 1.000      Min.   :187.0      Min.   :12.60
## 1st Qu.: 2.100      1st Qu.: 4.000      1st Qu.:279.0      1st Qu.:17.40
## Median : 3.207      Median : 5.000      Median :330.0      Median :19.05
## Mean   : 3.795      Mean   : 9.549      Mean   :408.2      Mean   :18.46
## 3rd Qu.: 5.188      3rd Qu.:24.000      3rd Qu.:666.0      3rd Qu.:20.20
## Max.   :12.127      Max.   :24.000      Max.   :711.0      Max.   :22.00
##           lstat           medv
##  Min.   : 1.73      Min.   : 5.00
## 1st Qu.: 6.95      1st Qu.:17.02
## Median :11.36      Median :21.20
## Mean   :12.65      Mean   :22.53
## 3rd Qu.:16.95      3rd Qu.:25.00
## Max.   :37.97      Max.   :50.00
```

`psych::describe(boston)`

```
##           vars      n      mean      sd median trimmed      mad      min      max      range      skew
## X              1 506 253.50 146.21 253.50 253.50 187.55      1.00 506.00 505.00 0.00
## crim           2 506   3.61   8.60   0.26   1.68   0.33   0.01 88.98 88.97 5.19
## zn             3 506  11.36  23.32   0.00   5.08   0.00   0.00 100.00 100.00 2.21
## indus          4 506  11.14   6.86   9.69  10.93   9.37   0.46 27.74 27.28 0.29
## chas           5 506   0.07   0.25   0.00   0.00   0.00   0.00  1.00  1.00 3.39
## nox            6 506   0.55   0.12   0.54   0.55   0.13   0.38  0.87  0.49 0.72
## rm             7 506   6.28   0.70   6.21   6.25   0.51   3.56  8.78  5.22 0.40
## age            8 506  68.57  28.15  77.50  71.20  28.98   2.90 100.00 97.10 -0.60
## dis            9 506   3.80   2.11   3.21   3.54   1.91   1.13 12.13 11.00 1.01
## rad           10 506   9.55   8.71   5.00   8.73   2.97   1.00 24.00 23.00 1.00
```

```

## tax      11 506 408.24 168.54 330.00 400.04 108.23 187.00 711.00 524.00 0.67
## ptratio  12 506 18.46  2.16 19.05 18.66  1.70 12.60 22.00  9.40 -0.80
## lstat    13 506 12.65  7.14 11.36 11.90  7.11  1.73 37.97 36.24 0.90
## medv     14 506 22.53  9.20 21.20 21.56  5.93  5.00 50.00 45.00 1.10
##          kurtosis  se
## X          -1.21 6.50
## crim       36.60 0.38
## zn         3.95 1.04
## indus     -1.24 0.30
## chas       9.48 0.01
## nox       -0.09 0.01
## rm        1.84 0.03
## age       -0.98 1.25
## dis        0.46 0.09
## rad       -0.88 0.39
## tax       -1.15 7.49
## ptratio   -0.30 0.10
## lstat      0.46 0.32
## medv      1.45 0.41

modello1 <- lm(medv ~ rm, data = boston)
summary(modello1)

##
## Call:
## lm(formula = medv ~ rm, data = boston)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -23.346  -2.547   0.090   2.986  39.433
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -34.671     2.650  -13.08  <2e-16 ***
## rm           9.102      0.419   21.72  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 6.616 on 504 degrees of freedom
## Multiple R-squared:  0.4835, Adjusted R-squared:  0.4825
## F-statistic: 471.8 on 1 and 504 DF, p-value: < 2.2e-16

range(boston$rm)


## [1] 3.561 8.780

mean(boston$rm)

## [1] 6.284634

corrplot(cor(boston), method = "square")

```




Dal calcolo della regressione lineare semplice risulta che l'intercetta β_0 è uguale a -34.671 e che il regressore β_1 aumenta di 9.102 per ogni unità di x . Ne deriva che il modello di regressione lineare semplice sarà rappresentato dalla formula:

$$\hat{y} = -39.671 + 9.102x$$


Si tratta ovviamente di un valore indicativo, considerato che non esistono abitazioni senza stanze e che, in media, una casa a Boston ha circa sei stanze al suo interno (mean = 6.284634). Dal valore dell'indice R^2 notiamo che il modello riesce a spiegare solo il 48% della variabilità del prezzo mediano, lasciando intendere che quest'ultimo potrebbe essere influenzato da altre osservazioni. Il grafico ci aiuta a visualizzare la correlazione tra le variabili, compreso il prezzo mediano e il numero di stanze per abitazione, che risulta, da un primo punto di vista, la correlazione positiva più forte.

```
ggplot(boston, aes(x = rm, y = medv,)) +
  geom_point() +
  labs(x = "Stanze",
       y = "Prezzo Mediano") +
  geom_smooth(method=lm, se=FALSE) +
  theme_minimal()

## `geom_smooth()` using formula = 'y ~ x'
```



```
d_scatola <- ggplot(boston, aes(medv)) +  
  geom_boxplot() +  
  theme_minimal()  
  
print(d_scatola)
```



Il diagramma a dispersione dimostra la presenza di una relazione lineare positiva tra le due variabili ($\text{medv} \sim \text{rm}$), per cui il prezzo medio tende ad aumentare parallelamente al numero di stanze presenti in un'abitazione. con una nube di punti che si concentra intorno ad un range di valori tra 5 e 7 (in riferimento alle stanze). Dal successivo diagramma a scatola, però, possiamo notare anche un alto numero di outlier, in particolar modo nel baffo superiore. Mentre il 50% delle osservazioni ci suggerisce che il prezzo medio per abitazione oscilla tra il 17.000 e i 25.000 dollari, l'alta presenza di outlier ci porta a ipotizzare che la pendenza della retta di regressione possa essere influenzata in una certa misura da essi.

```
confint(modello1)
```

```
##           2.5 %      97.5 %
## (Intercept) -39.876641 -29.464601
## rm          8.278855   9.925363
```

Calcolando gli intervalli di confidenza siamo sicuri al 95% che il valore dell'intercetta β_0 si troverà nell'intervallo di valori tra -39.876641 e -29.464601, mentre, per quanto riguarda il regressore β_1 , siamo sicuri al 95% che l'impatto del numero stanze sul prezzo medio delle case sarà rappresentato da un valore compreso tra 8.278855 e 9.925363 migliaia di dollari.

Come detto in precedenza, in media un'abitazione a Boston ha al suo interno circa 6 stanze. Proviamo a calcolare, dunque, gli intervalli di confidenza e gli intervalli di previsione basandoci su questo valore:

```
predict(modello1, data.frame(rm = (6)),
        interval = "confidence")

##          fit          lwr          upr
## 1 19.94203 19.31847 20.5656

predict(modello1, data.frame(rm = (6)),
        interval = "prediction")

##          fit          lwr          upr
## 1 19.94203 6.928435 32.95563
```

L'intervallo di confidenza suggerisce che il prezzo medio di una casa con sei stanze a Boston si attesta a poco meno di 20.000 dollari, con un valore minimo di 19.31847 dollari e un valore massimo di 20.5656 dollari. Mentre in questo primo caso vi è un intervallo piuttosto piccolo, in quanto calcoliamo la media del valore di tutte le abitazioni con 6 stanze, nel secondo caso, quello dell'intervallo di previsione, troviamo un range più ampio, perché ci concentriamo su una singola osservazione. Nello specifico, mentre il prezzo medio previsto è sempre uguale a 19.94203 dollari, i valori minimo e massimo previsti saranno uguali rispettivamente a 6.928435 dollari e 32.95563 dollari.

Considerato che la variabile esplicativa *rm* è in grado di spiegare solo il 48% della variabilità del prezzo mediano di un'abitazione, potremmo potenziare la nostra analisi aggiungendo una seconda variabile esplicativa, ovvero, *lstat*, in riferimento alla percentuale di zone a basso reddito:

```
modello2 <- lm(medv ~ rm + lstat, data = boston)
summary(modello2)

##
## Call:
## lm(formula = medv ~ rm + lstat, data = boston)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -18.076  -3.516  -1.010   1.909   28.131
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -1.35827     3.17283  -0.428    0.669
## rm           5.09479     0.44447  11.463 <2e-16 ***
## lstat        -0.64236     0.04373 -14.689 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
```

```
## Residual standard error: 5.54 on 503 degrees of freedom
## Multiple R-squared:  0.6386, Adjusted R-squared:  0.6371
## F-statistic: 444.3 on 2 and 503 DF,  p-value: < 2.2e-16
```

Tale modello di regressione lineare multipla è rappresentato dalla formula:

$$\hat{y} = -1.35827 + 5.09479x_1 - 0.64236x_2$$

per cui l'intercetta β_0 è uguale a -1.35827 (anche in questo caso è un valore indicativo), mentre i regressori β_1 e β_2 sono uguali a 5.09479 e -0.64236. Grazie alla variabile lstat notiamo che il modello è ora in grado di spiegare il 64% della variabilità di medv ($R^2 = 0.6371$), anche se i p-value associati all'intercetta risultano superiori allo 0,5 (p-value = 0.669).

Prendendo in considerazione la media di lstat (12%) proviamo a calcolare gli intervalli di confidenza e di previsione insieme alla media di rm (6 stanze):

```
mean(boston$lstat)

## [1] 12.65306

predict(modello2, data.frame(rm = (6), lstat = (12)),
        interval = "confidence")


##          fit          lwr          upr
## 1 21.50216 20.93984 22.06447

predict(modello2, data.frame(rm = (6), lstat = (12)),
        interval = "prediction")

##          fit          lwr          upr
## 1 21.50216 10.60274 32.40157
```

Ne consegue che la media del prezzo di una casa a Boston con sei stanze e la presenza in zona di circa il 12% di popolazione appartenente a contesti socio-economici svantaggiati sia di 21.50216 dollari, con intervalli di confidenza che vanno da 20.93984 a 22.06447 migliaia di dollari e intervalli di previsione che vanno da 10.60274 a 32.40157 migliaia di dollari.

```
plot(predict(modello2), residuals(modello2))
```

Come possiamo vedere dal grafico, i residui del modello di previsione (modello2) oscillano in modo casuale attorno allo zero.